ΠΑΝΕΠΙΣΤΗΜΙΟ ΔΥΤΙΚΗΣ ΑΤΤΙΚΗΣ

UNIVERSITÉ DE LIMOGES

AIVC MSc in Artificial Intelligence & Visual Computing

Βαθιά Μάθηση

Εργασία Εξαμήνου 2025

Μπαντησούλη Αγαθή ΑΜ: aivc24010

Θέμα: «Εφαρμογή Μοντέλων και Μεθόδων Βαθιάς Μηχανικής Μάθησης»

Μέρος 1ο

Στο μέρος αυτό, θα ασχοληθούμε με την εφαρμογή μοντέλων βαθιάς μηχανικής μάθησης για ταξινόμηση, χρησιμοποιώντας ένα ευρέως γνωστό σύνολο δεδομένων ανοιχτής πρόσβασης, το CIFAR-100.

Πρέπει να επιλεγούνε και να εκπαιδευτούνε 2 διαφορετικά μοντέλα, χρησιμοποιώντας το 70%, το 60% και το 50% του αρχικού dataset. Επιλέχθηκαν λοιπόν τα μοντέλα VGG-16 και ResNet50, τα οποία αποτελούν καθιερωμένα benchmarks στη βιβλιογραφία (Riza et al., 2021).

VGG-16

Το VGG-16, αποτελεί ένα από τα πιο γνωστά convolutional neural networks, που χρησιμοποιείται για την αναγνώριση εικόνων. Η αρχιτεκτονική του, βασίζεται κυρίως στην χρήση πολλών μικρών 3x3 convolutional filters, με σταδιακή αύξηση των φίλτρων σε βάθος και χρήση max-pooling για spatial downsampling (Simonyan & Zisserman, 2015). Το 16 στο όνομά του, αναφέρεται στα 16 επίπεδα που έχουν βάρη. Στο VGG-16 υπάρχουν 13 convolutional layers, 5 Max Pooling layers και 3 Dense layers, συνολικά δηλαδή 21 επίπεδα. Παρόλα αυτά, μόνο 16 στρώσεις βάρους, δηλαδή στρώμα παραμέτρων, έχουν την ικανότητα να μαθευτούν. Επιπροσθέτως, το VGG-16, παίρνει μέγεθος τανυστή εισόδου ως 224, 244 με 3 κανάλια RGB. Ακόμα, τα στρώματα συνέλιξης αλλά και τα max pool, είναι διατεταγμένα με συνέπεια σε ολόκληρη την αρχιτεκτονική του μοντέλου. Το 1ο επίπεδο έχει 64 φίλτρα, το 2ο έχει 128, το 3ο 256 και το 4ο και 5ο, 512 φίλτρα. Τέλος, αναφορικά με τα 3 Fully-Connected (FC) layers μπορούμε να πούμε ότι ακολουθούν μία στοίβα συνελικτικών επιπέδων: τα δύο πρώτα έχουν 4096 κανάλια το καθένα, το τρίτο εκτελεί ταξινόμηση ILSVRC 1000 κατευθύνσεων και επομένως περιέχει 1000 κανάλια (ένα για κάθε κλάση) και το τελευταίο επίπεδο, είναι το επίπεδο soft-max.

Το μοντέλο απαιτεί είσοδο 224×224×3, οπότε έγινε resize των εικόνων του CIFAR-100. Η αρχική προσπάθεια περιλάμβανε εκπαίδευση του μοντέλου από την αρχή (weights=None), χωρίς προεκπαιδευμένα βάρη. Ωστόσο, διαπιστώθηκαν τα εξής: Αρχικά είχαμε πολύ υψηλό υπολογιστικό κόστος, αλλά και χαμηλότερη απόδοση σε accuracy και F1-score. Για να αντιμετωπιστεί αυτό, εφαρμόστηκε transfer learning. Χρησιμοποιήθηκαν προεκπαιδευμένα βάρη από το ImageNet, όλα τα layers

πάγωσαν (requires_grad = False) και εκπαιδεύτηκε μόνο το τελικό πλήρως συνδεδεμένο layer (Linear(4096, 100)). Η εκπαίδευση πραγματοποιήθηκε σε GPU (CUDA), με: batch size=64, epochs=10, learning rate=0.001, optimizer=Adam και loss function=CrossEntropyLoss.

ResNet-50

Εν συνεχεία, το δεύτερό μου μοντέλο όπως προαναφέρθηκε, είναι το ResNet-50. Είναι ένα πολύ ισχυρό μοντέλο ταξινόμησης εικόνων, που μπορεί να εκπαιδευτεί σε μεγάλα dataset. Η βασική καινοτομία του ResNet είναι η χρήση residual connections (skip connections), οι οποίες επιτρέπουν την εκπαίδευση πολύ βαθιών δικτύων χωρίς προβλήματα υποβάθμισης (degradation) (He et al., 2016). Η αρχιτεκτονική του, χωρίζεται σε 4 κύρια μέρη: τα συνελικτικά επίπεδα, το identity μπλοκ, το συνελικτικό μπλοκ και τα fully connected επίπεδα. Τα συνελικτικά επίπεδα είναι υπεύθυνα για την εξαγωγή χαρακτηριστικών από την εικόνα εισόδου, ενώ το μπλοκ ταυτότητας και το συνελικτικό μπλοκ είναι υπεύθυνα για την επεξεργασία και τον μετασχηματισμό αυτών των χαρακτηριστικών. Τέλος, τα πλήρως συνδεδεμένα επίπεδα χρησιμοποιούνται για την τελική ταξινόμηση. Συγκεκριμένα, η έκδοση ResNet-50 αποτελείται από 50 layers και Residual blocks με bottleneck layers

Η εκπαίδευση έγινε με τον ίδιο διαχωρισμό δεδομένων (70%, 60%, 50%), και παρουσιάζονται τα αποτελέσματα ακρίβειας, recall, precision και F1-score. Αξιοποιήθηκαν επιπλέον τεχνικές όπως learning rate scheduling και τεχνικές κανονικοποίησης (He et al., 2019).

	50% training set				60% training set			
	accuracy	**recall**	**precision**	**F1-score**	**accuracy**	**recall**	**precision**	**F1-score**
MODEL A	0.6069	0.6069	0.6258	0.6024	0.6045	0.6045	0.6218	0.6001
MODEL B	0.5733	0.5733	0.6296	0.5719	0.5837	0.5837	0.6275	0.5859

	70% training set			
	accuracy	**recall**	**precision**	**F1-score**
MODEL A	0.6170	0.6170	0.6334	0.6127
MODEL B	0.5839	0.5839	0.6378	0.5825

Έξτρα Σχολιασμός

Από την ανάλυση των αποτελεσμάτων παρατηρείται ότι το μοντέλο VGG-16 επιτυγχάνει σταθερά καλύτερη απόδοση σε σχέση με το ResNet-50, ανεξαρτήτως του ποσοστού των δεδομένων εκπαίδευσης. Συγκεκριμένα, στο training split 70%, το VGG-16 παρουσιάζει ακρίβεια 60.7% και F1-score 60.2%, υπερτερώντας του ResNet-50 που φτάνει τα 57.3% και 57.2% αντίστοιχα. Η διαφορά αυτή διατηρείται και στα μικρότερα splits (60% και 50%), υποδηλώνοντας ότι το VGG-16 είναι πιο ανθεκτικό στη μείωση των δεδομένων εκπαίδευσης.

Επιπροσθέτως, πρέπει να αναφερθεί ότι ενώ το ResNet-50 εμφανίζει ελαφρώς υψηλότερη precision σε όλα τα splits, το F1-score του είναι πιο χαμηλό. Το αποτέλεσμα αυτό, μας δείχνει χαμηλότερη ισορροπία μεταξύ των precision και recall. Αντίθετα, το VGG-16 διατηρεί σταθερή συμπεριφορά με ελαφρώς υψηλότερο recall και συνολικά πιο ισορροπημένη απόδοση.

Τα παραπάνω υποδηλώνουν ότι, για το dataset CIFAR-100 και το συγκεκριμένο πλαίσιο εφαρμογής, η αρχιτεκτονική του VGG-16 , σε συνδυασμό με μεταφορά μάθησης αποδίδει καλύτερα, πιθανόν λόγω της απλούστερης και καλύτερης δομής της, σε σχέση με την πιο πολύπλοκη ResNet-50.

Τέλος, στο πρόγραμμα που δημιουργήθηκε υπάρχουν και διαγράμματα για σύγκριση train/val Loss και train/val Accuracy.

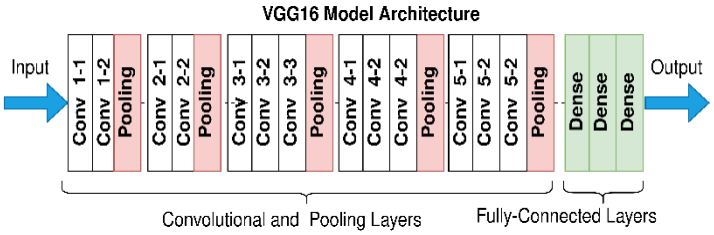
Βιβλιογραφία

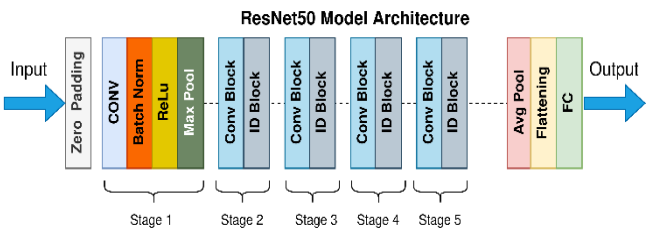
He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE conference on computer vision and pattern recognition*, 770–778.

He, T., Zhang, Z., Zhang, H., Zhang, Z., Xie, J., & Li, M. (2019). Bag of tricks for image classification with convolutional neural networks. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 558–567.

Riza, H. R., Hakim, R. L., Rahmawati, D., & Afriani, Y. (2021). Image classification using VGG and ResNet models. *Journal of Physics: Conference Series*, 2711(1), 012015.

Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. *International Conference on Learning Representations (ICLR)*.





Μέρος 2ο

Στο μέρος αυτό, η εργασία αφορά την επιλογή, επεξεργασία και αξιολόγηση μοντέλων σε δεδομένα εικόνας, τα οποία περιέχουν labels για tasks όπως segmentation, detection ή classification. Στο πλαίσιο αυτής της εργασίας, έγινε επιλογή του EuroSAT Dataset.

Το EuroSAT, είναι ένα σύνολο δεδομένων το οποίο βασίζεται σε δορυφορικές εικόνες Sentinel-2 του Ευρωπαϊκού Οργανισμού Διαστήματος (ESA) και χρησιμοποιείται για το πρόβλημα της ταξινόμησης χρήσεων γης, αλλά και της κάλυψης γης. Οι εικόνες καλύπτουν 13 φασματικές ζώνες και αποτελείται από 10 κατηγορίες LULC με συνολικά 27.000 επισημασμένες και γεωαναφερόμενες εικόνες. Το κύριο πρόβλημα που πρέπει να αντιμετωπιστεί, είναι η ταξινόμηση περιοχών σε διάφορες κατηγορίες, όπως είναι δάσος, αστική περιοχή, βιομηχανική ζώνη, γεωργική γη κ.ά., με βάση το πώς φαίνονται από τις εικόνες. Είναι καίριας σημασίας η αυτόματη αναγνώριση τέτοιων περιοχών και έχει μεγάλο πλεονέκτημα σε διάφορες εφαρμογές, όπως στην παρακολούθηση περιβαλλοντικών αλλαγών, στο σχεδιασμό πόλεων και στη διαχείριση φυσικών πόρων, αλλά και σε εφαρμογές στην αγροτεχνολογία και στη χαρτογράφηση. Το βασικότερο πρόβλημα, εντοπίζεται στην πολυπλοκότητα αυτών των οπτικών πληροφοριών, καθώς έχουμε να επεξεργαστούμε διαφορετικές εποχές, φωτισμό, επήρεια κλιματικών αλλαγών (κάλυψη από σύννεφα) και μεγάλη ποικιλία υφών. Το δεύτερο πρόβλημα, αφορά στην μεγάλη ομοιότητα μεταξύ κάποιων περιοχών, γεγονός που δυσκολεύει την ακριβή ταξινόμηση από μοντέλα μηχανικής μάθησης.

Η ταξινόμηση δορυφορικών εικόνων, αποτελεί ένα από τα βασικά προβλήματα στην ανάλυση γεωχωρικών δεδομένων, με διάφορες εφαρμογές κυρίως στην γεωργία, την πολεοδομία, την χαρτογράφηση, αλλά και την περιβαλλοντική παρακολούθηση. Τα τελευταία χρόνια, με την βοήθεια των Deep Neural Networks, το πρόβλημα της ταξινόμησης έχει πλέον αρχίσει να μειώνεται. Το ResNet-50, αποτελεί ένα από τα πιο γνωστά μοντέλα, το οποίο εισήγαγε την έννοια των residual connections επιτρέποντας την εκπαίδευση πολύ βαθιών δικτύων (He et al., 2016). Το ResNet έχει χρησιμοποιηθεί με επιτυχία στο dataset EuroSAT, όπως φαίνεται στη μελέτη των Helber et al. (2019), στην οποία η εφαρμογή ενός CNN σε εικόνες Sentinel-2 οδήγησε σε ακρίβεια 98.57% στην ταξινόμηση χρήσεων γης. Ακόμα, στην βιβλιογραφία μπορούμε να βρούμε μοντέλα που εστιάζουν κυρίως στην υπολογιστική αποδοτικότητα, όπως είναι το EfficientNet-B0. Οι Tan και Le (2019) παρουσίασαν μια μέθοδο scaling του βάθους, πλάτους και ανάλυσης του μοντέλου, που επιτρέπει υψηλή ακρίβεια με περιορισμένους πόρους. Αυτό καθιστά το EfficientNet-B0 ιδανικό για περιβάλλοντα χαμηλής υπολογιστικής ισχύος, όπως embedded συστήματα επεξεργασίας γεωχωρικών δεδομένων. Πιο πρόσφατες μελέτες, εισάγουν τα Vision Transformers, που βασίζονται στον μηχανισμό self-attention, αντί για συνελικτικά φίλτρα. Το Swin Transformer Tiny, μια πιο ελαφριά εκδοχή, έδειξε εξαιρετικά αποτελέσματα σε εικόνες με σύνθετα patterns, όπως οι

δορυφορικές [Liu et al., 2021]. Αντίστοιχα, το Vision Transformer (ViT) που προτάθηκε από τους Dosovitskiy et al. (2020), θεωρείται σήμερα ένα ισχυρό baseline για ταξινόμηση εικόνων μεγάλης ανάλυσης. Επιπροσθέτως, στην μελέτη των Ren et al. (2022), έγιναν αναλυτικές συγκρίσεις μοντέλων, όπου αναφέρεται ότι μοντέλα όπως τα AlexNet, VGG, GoogleNet και MobileNet, μπορούν να πετύχουν πολύ υψηλά ποσοστά ακρίβειας. Τέλος, η εργασία των Zhao et al. (2019) παρουσιάζει μια συγκριτική μελέτη CNNs σε εικόνες Sentinel-2, ενσωματώνοντας τόσο παραδοσιακά όσο και σύγχρονα deep learning μοντέλα και η μελέτη των Liu et al. (2018), εξετάζει την απόδοση ResNet, GoogleNet και άλλων CNNs σε πολυφασματικά δεδομένα, προσφέροντας σημαντική θεωρητική βάση για την επιλογή μοντέλων σε δορυφορικές εφαρμογές.

Προχωρώντας, όσον αφορά το dataset που χρησιμοποιήθηκε, προτάθηκε από τους Helber et al. (2019) και έχει σχεδιαστεί για την υποστήριξη εφαρμογών στην τηλεπισκόπηση και την ανάλυση γεωχωρικών δεδομένων. Το EuroSAT περιλαμβάνει 27.000 εικόνες ανάλυσης 64x64 pixels, οι οποίες έχουν εξαχθεί από 13 φασματικά κανάλια του Sentinel-2. Οι εικόνες αυτές έχουν κατανεμηθεί σε 10 κατηγορίες (classes) που σχετίζονται με διαφορετικές χρήσεις γης και καλύψεις, όπως: Residential, Industrial, Annual Crop, Forest, River, Sea/Lake, Permanent Crop, Pasture, Highway και Herbaceous Vegetation.

Για την εκπαίδευση στο EuroSAT dataset επιλέχθηκαν τρία διαφορετικά μοντέλα ResNet-50, EfficientNet-B0 και Swin Transformer Tiny.

ResNet-50

Η αρχιτεκτονική ResNet (He et al., 2016) στηρίζεται στην εισαγωγή των residual blocks, δηλαδή συνδέσεων που παρακάμπτουν ενδιάμεσα επίπεδα (skip connections). Αυτό επιτρέπει την εκπαίδευση πολύ βαθιών δικτύων, χωρίς πρόβλημα υποβάθμισης (degradation). Το ResNet-50 αποτελείται από 50 επίπεδα, με χρήση 3×3 και 1×1 convolutional φίλτρων, Batch Normalization και ReLU. Είναι εξαιρετικά σταθερό, και χρησιμοποιείται ευρέως για tasks τηλεπισκόπησης, όπως στην εργασία των Helber et al. (2019) στο EuroSAT. Χρειάστηκαν 7666.48 δευτερόλεπτα χρόνο εκπαίδευσης με Accuracy = 97.73% και Macro F1-score = 97.60%.

EfficientNet-B0

Το EfficientNet-B0 (Tan & Le, 2019) βασίζεται στην αρχή του compound scaling, δηλαδή της ταυτόχρονης και ισορροπημένης αύξησης του βάθους, του πλάτους και της ανάλυσης της εισόδου. Χρησιμοποιεί Mobile Inverted Bottleneck Convolutions (MBConv), με ενσωματωμένο squeeze-and-excitation μηχανισμό, βελτιώνοντας τη μοντελοποίηση διακαναλικών σχέσεων. Η αρχιτεκτονική ξεκινά με ένα 3×3 convolution, ακολουθούμενο από μια ακολουθία από MBConv blocks και τελειώνει με global average pooling και ένα πλήρως συνδεδεμένο επίπεδο. Χρειάστηκαν

5368.91 δευτερόλεπτα χρόνο εκπαίδευσης με Accuracy = 98.89% και Macro F1-score = 98.84%.

Swin Transformer Tiny

Το Swin Transformer (Liu et al., 2021), αποτελεί παραλλαγή του Vision Transformer (ViT), σχεδιασμένη για να λειτουργεί ιεραρχικά. Αντί για global self-attention, το Swin εφαρμόζει local self-attention μέσα σε “shifted windows”, επιτρέποντας μείωση της πολυπλοκότητας. Η αρχιτεκτονική του Swin Tiny αποτελείται από το πρώτο στάδιο (patch partitioning),τις σειρές από Swin Transformer blocks με Multi-Head Self Attention (MHSA) και Feed-Forward Networks (FFN) και την συμπίεση μέσω patch merging. Χρειάστηκαν 11656.25 δευτερόλεπτα χρόνο εκπαίδευσης, με Accuracy = 98.69% και Macro F1-score = 98.63%.

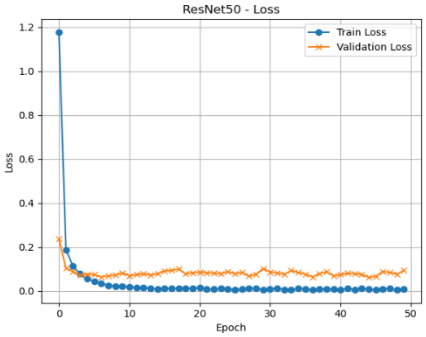
Όλα τα μοντέλα εκπαιδεύτηκαν με fine-tuning από προεκπαιδευμένα βάρη, στο ImageNet. Η εκπαίδευση έγινε σε περιβάλλον PyTorch με χρήση της βιβλιοθήκης timm. Η προεπεξεργασία των δεδομένων, περιλάμβανε αλλαγή του μεγέθους των εικόνων 224x244 pixels, κανονικοποίηση βάσει των στατιστικών του ImageNet και κατανομή του συνόλου σε 70% training, 15% validation και 15% test. Ως Frameworks χρησιμοποιήθηκαν οι βιβλιοθήκες torchvision, timm και scikit-learn. Χρησιμοποιηθήκαν επίσης οι παρακάτω τιμές για τις υπερπαραμέτρους: epochs = 50, batch size = 32, optimizer = Adam (weight decay), learning rate = 1e-4, loss function = CrossEntropyLoss και Scheduler (προαιρετικά): ReduceLROnPlateau για μείωση του learning rate σε περίπτωση στασιμότητας. Η εκπαίδευση πραγματοποιήθηκε σε σύστημα με GPU.

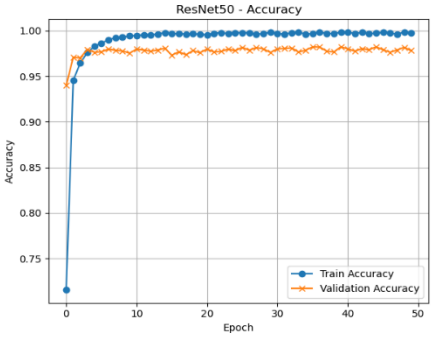
Τελευταίο βήμα ήτανε η αξιολόγηση και ανάλυση των τριών μοντέλων, η οποία πραγματοποιήθηκε στο test set του EuroSAT dataset, χρησιμοποιώντας τις μετρικές accuracy, precision, recall, F1-score (macro και weighted average), καθώς και ποιοτική ανάλυση μέσω visualizations, όπως confusion matrices, κάποια διαγράμματα από το κομμάτι της εκπαίδευσης, αλλά και παραδείγματα εξόδου.

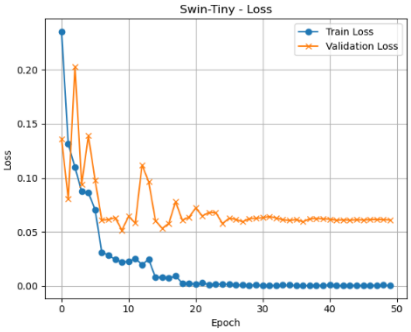
Μοντέλο	Accuracy	Macro F1-score	Χρόνος Εκπαίδευσης
ResNet-50	97.73%	97.60%	7666 sec
Swin Transformer	98.69%	98.63%	11656 sec
EfficientNet-B0	**98.89%**	**98.84%**	**5368 sec**

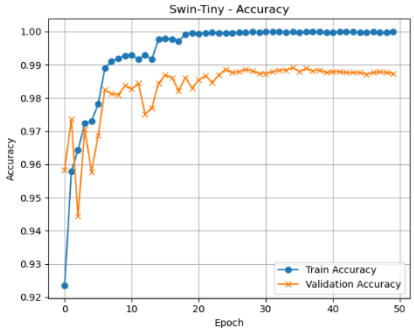
Και τα 3 μοντέλα πέτυχαν εξαιρετική ακρίβεια, με το EfficientNet-B0 να υπερέχει ελαφρώς σε όλα τα επίπεδα, επιτυγχάνοντας υψηλή απόδοση με τον μικρότερο χρόνο εκπαίδευσης. Το Swin Transformer Tiny, παρά το μεγαλύτερο υπολογιστικό κόστος, προσέφερε εξίσου υψηλή ακρίβεια, χάρη στη δύναμη του self-attention. Το ResNet-50 λειτούργησε ως σταθερό baseline.

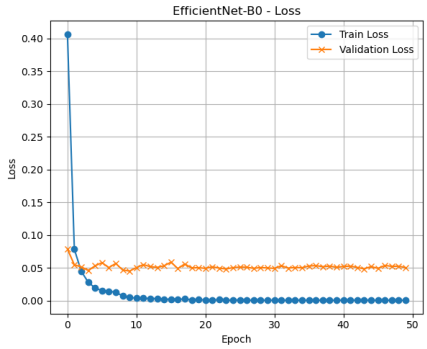
Επιπροσθέτως, και τα 3 παρουσίασαν γρήγορη σύγκλιση της loss και σταθεροποίηση της validation accuracy. Συγκεκριμένα, το ResNet-50 έδειξε σταθερότητα, αλλά εμφάνισε μεγαλύτερη διακύμανση στα validation metrics, το Swin Transformer εμφάνισε κάποιες διακυμάνσεις στα πρώτα epochs, αλλά σταθεροποιήθηκε, και το EfficientNet-B0 είχε τη χαμηλότερη τελική validation loss και την πιο ομαλή εξέλιξη.

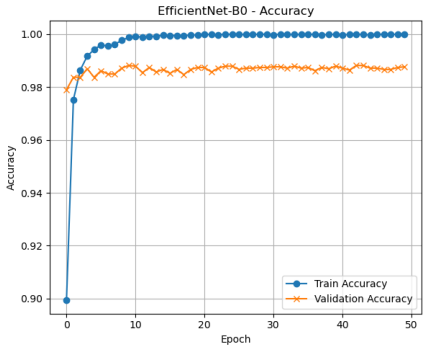


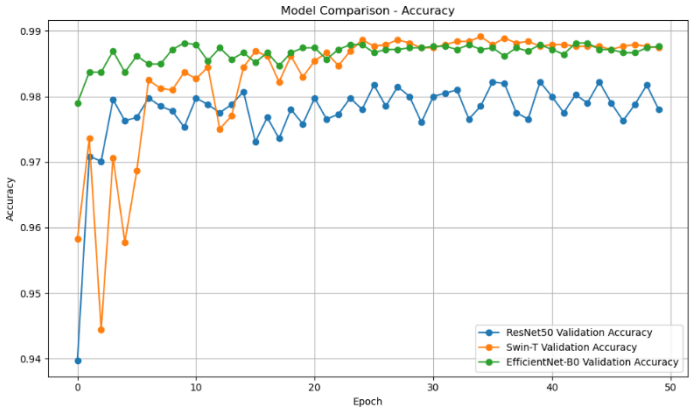


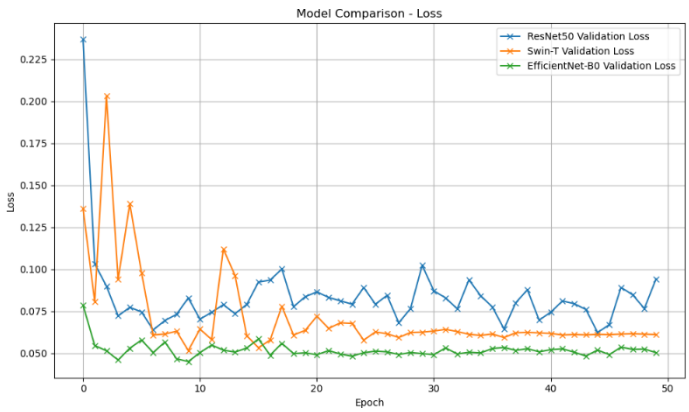






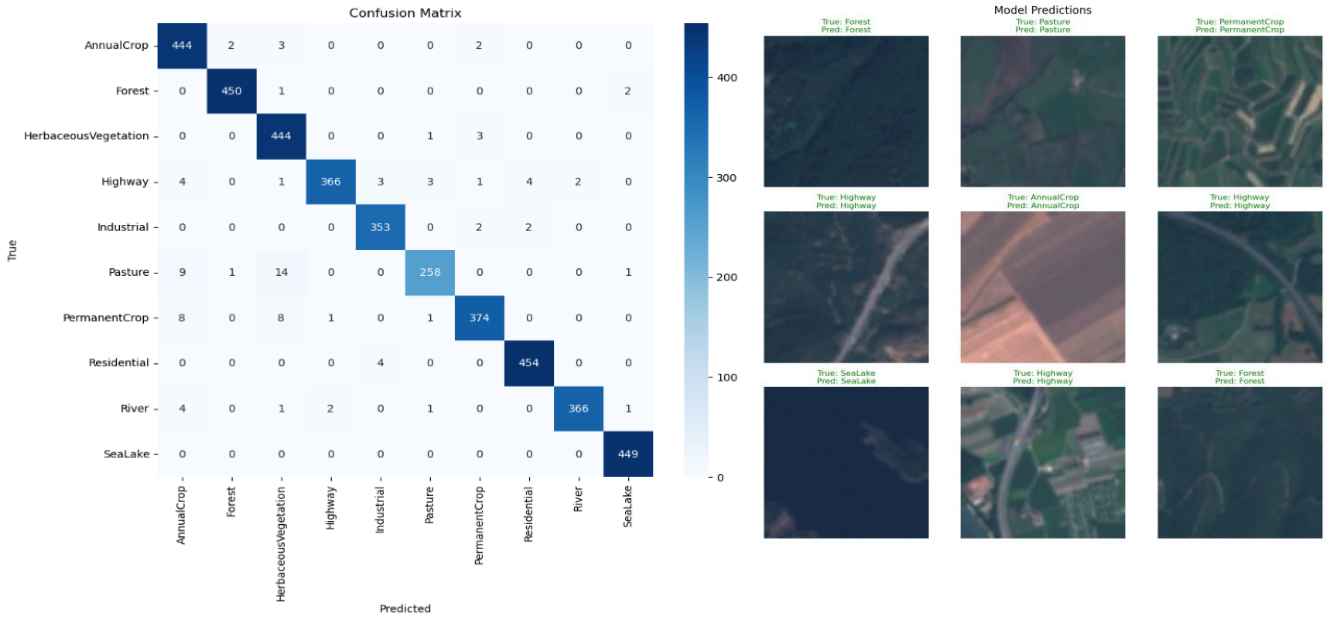




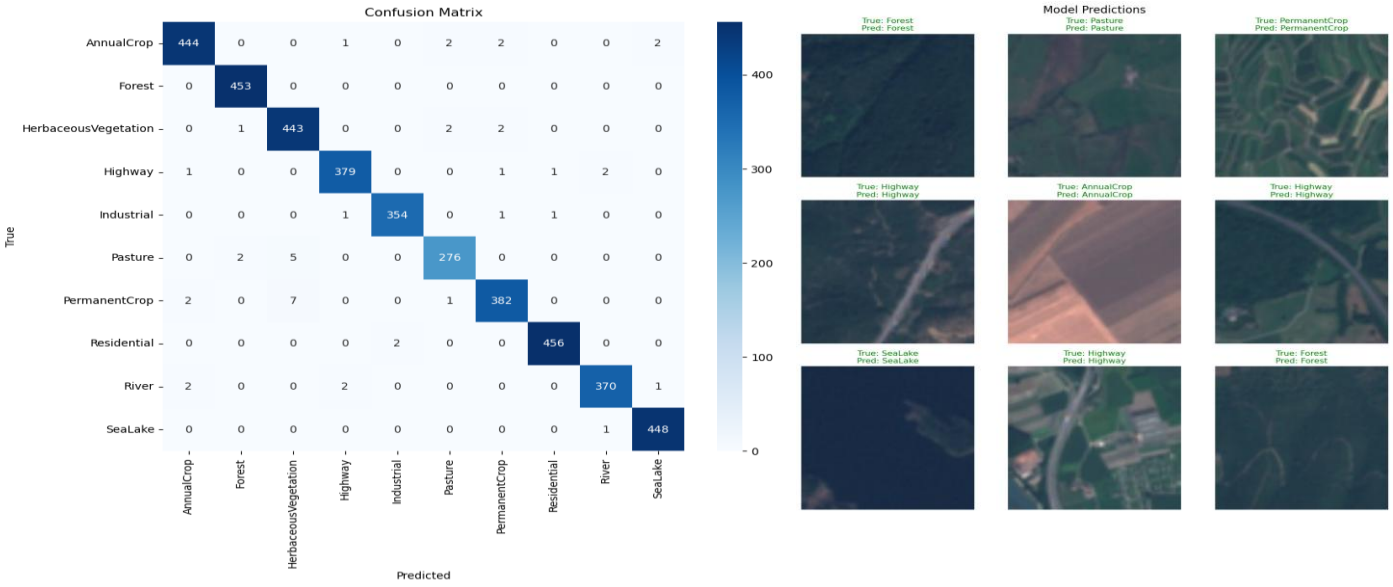


Τα οπτικά παραδείγματα, δείχνουν τις προβλέψεις μοντέλων σε πραγματικές εικόνες του EuroSAT. Παρατηρείται ότι η πλειοψηφία των προβλέψεων είναι σωστές. Επίσης, μικρές αποτυχίες εμφανίζονται σε περιπτώσεις, όπου 2 κλάσεις μοιάζουν οπτικά (π.χ. "Highway" vs. "AnnualCrop") και ορισμένες κατηγορίες που έχουν χαμηλή διακριτότητα (π.χ. διαφορετικοί τύποι πρασίνου), επηρεάζουν την ταξινόμηση.

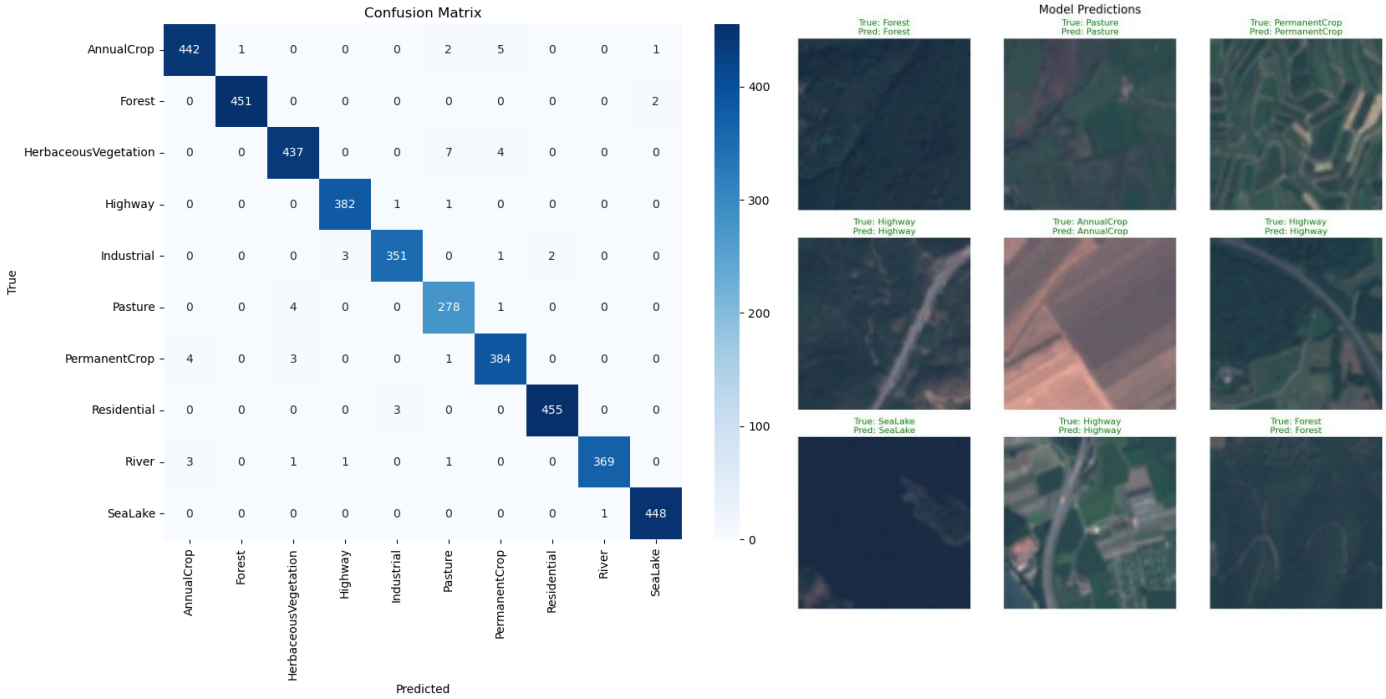
ResNet-50



Swin Transformer Tiny



EfficientNet-B0



Σύμφωνα λοιπόν με όλα τα παραπάνω αποτελέσματα, το EfficientNet-B0 αποτελεί εξαιρετική επιλογή για πρακτικές εφαρμογές λόγω υψηλής ακρίβειας και χαμηλού κόστους. Επίσης, το Swin Transformer προτείνεται όταν υπάρχει διαθέσιμη GPU και ανάγκη για προηγμένη κατανόηση χωρικών σχέσεων. Τέλος, το ResNet-50, αν και λιγότερο αποδοτικό σε σχέση με τα άλλα, παραμένει μια σταθερή και ερμηνεύσιμη λύση.

Για βελτιώσεις των μοντέλων, θα ήταν χρήσιμες και οι παρακάτω συμβουλές: Χρήση multispectral channels (όχι μόνο RGB), Data augmentation, αλλά και χρήση Ensemble μοντέλων για περαιτέρω αύξηση ακρίβειας.

Βιβλιογραφία

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. CVPR.

Helber, P., Bischke, B., Dengel, A., & Borth, D. (2019). EuroSAT: A Novel Dataset and Deep Learning Benchmark for Land Use and Land Cover Classification. IEEE GRSL.

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML.

Dosovitskiy, A., et al. (2020). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR.

Liu, Z., et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. ICCV.

Ren, L., et al. (2022). Evaluation of Lightweight CNNs for Satellite Image Classification. IEEE.